

Caso Practico

Risk Data Scientist

Modelos Predictivos de Score de Riesgo Crediticio

GLM (OLS Log-Normal) + LightGBM (Gradient Boosting Tweedie)

0.368

R2 Test

LightGBM

0.587

Gini

2xAUC-1

0.444

KS

Kolmogorov-Smirnov

S/. 4,675

RMSE

Error prediccion

Josef Rodriguez Mimbela

josef.rodrim@gmail.com | Junio 2026

Interfaz web: modelo-task.vercel.app

API REST: modelo-task.vercel.app/docs


Codigo fuente: github.com/josefrodrim/MODELO_TASK

Contenido

-	Dataset	50,000 observaciones, 12 variables predictoras, TARGET continuo
a.	Modelos: GLM + LightGBM	OLS Log-Normal (metodologia tradicional) + Gradient Boosting (ML)
b.	Supuestos de cada modelo	Evaluacion de supuestos estadisticos e impacto en resultados
c.	Preprocesamiento	Missing, outliers, transformaciones, imputacion y feature engineering
d.	Metricas y Comparacion	AUC, KS, Gini, R2, RMSE — comparacion en conjunto de test
e.	Interpretacion de Variables	Coherencia con el negocio/riesgo, SHAP values
f.	Seleccion del Modelo	Cual implementaria, trade-offs performance/interpretabilidad y riesgos
g.	Estabilidad y Monitoreo	PSI, cambios en distribucion poblacional, estrategia de alertas
h.	Modelo en Produccion	Entrenamiento, scoring, monitoreo — arquitectura y API desplegada


Dataset

El dataset contiene **50,000 observaciones** con 12 variables predictoras (X1-X12) y una variable objetivo continua (TARGET) que representa un score de credito en el rango **S/. 1,000-40,000** (media S/. 8,425). La distribucion es claramente asimetrica positiva (right-skewed), lo que justifica la transformacion logaritmica en el GLM y el objetivo Tweedie en LightGBM. Particion predefinida: **33,334 train** (BASE = TRAIN) y **16,667 test** (BASE = TEST).




Distribucion del TARGET en train. Cola positiva tipica de scores crediticios.

Distribucion train vs. test. Alta similitud poblacional.



Tasa de valores faltantes por variable. X3 y X4 contienen ademas centinelas (-9999998).



Distribuciones de X1-X12. Se aprecian diferente escala y asimetría entre variables.

a. Modelos: GLM y LightGBM

Se desarrollan dos modelos de regresion para estimar el TARGET: uno con metodologia tradicional (GLM) y otro con Machine Learning (LightGBM). Ambos reciben exactamente el mismo conjunto de 47 features procesadas por el pipeline **RiskPreprocessor**.

GLM — Modelo Lineal Generalizado (OLS Log-Normal)

Se estima OLS sobre **log(TARGET)**, equivalente a un GLM con distribucion log-normal y funcion link logaritmica. La prediccion en escala original es $Y_{\hat{}} = \exp(X * \beta)$. Las variables se seleccionaron por backward elimination (umbral $p > 0.05$) y control de multicolinealidad ($VIF < 5$). Resultado: **R2 test = 0.291**, **Gini = 0.545**.




Figura a.1 — Coeficientes estandarizados del GLM con intervalos de confianza al 95%.

LightGBM — Gradient Boosting con objetivo Tweedie (ML)

LightGBM se selecciona como modelo ML tras evaluar tambien XGBoost y CatBoost. El objetivo **Tweedie** (variance_power=1.64) modela directamente la distribucion right-skewed del TARGET. Los hiperparametros se buscan con **Optuna TPE** (30 trials, 3-fold CV) y el modelo se detiene con early stopping (50 rondas). Resultado: **R2 test = 0.368**, **Gini = 0.587**, 731 arboles finales.

Parametro	Valor	Justificacion
objective	tweedie	Distribucion continua positiva right-skewed
variance_power	1.64 (Optuna)	Optimizado en CV; entre Poisson (1.0) y Gamma (2.0)
n_estimators	731 (early stop)	50 rondas sin mejora en validation loss
num_leaves	63	Balanceo profundidad/overfitting en Optuna
learning_rate	0.047	Encontrado por Optuna TPE Sampler (30 trials)

b. Supuestos de cada modelo

El GLM (OLS) requiere cumplir supuestos estadísticos clásicos. LightGBM, al ser no paramétrico, no los exige — pero tiene sus propios requisitos operativos. A continuación se evalúa cada supuesto y su impacto en los resultados.

GLM — Evaluación de supuestos (OLS sobre log-TARGET)

Supuesto	Test	Resultado	Impacto
Normalidad de residuos	Jarque-Bera	Violado	Residuos leptocúrticos. No invalida el modelo pero si los IC clásicos (requieren bootstrap).
Homocedasticidad	Breusch-Pagan	Violado	Varianza de residuos crece con el nivel del score. Los estimadores OLS siguen siendo insesgados pero ineficientes.
Autocorrelación	Durbin-Watson = 2.00	OK	Residuos no correlacionados en orden de registro. No hay patrón temporal problemático.
Multicolinealidad	VIF máximo < 5	OK	Variables independientes tras eliminar colineales y el target encoding de X9.
Linealidad	Inspección visual	Parcial	Las transformaciones log y las interacciones capturan la mayoría de la no-linealidad residual.

Diagnóstico de Supuestos del Modelo GLM




Figura b.1 — Diagnósticos de supuestos del GLM: residuos vs fitted, Q-Q-plot, escala-localización y leverage.

LightGBM — Consideraciones en lugar de supuestos

Aspecto	Evaluacion	Impacto
Distribucion de residuos	No requerida — no parametrico	Tweedie maneja asimetria directamente; no necesita transformacion del TARGET.
Overfitting	Gap R2 train-test = 0.099	Moderado pero controlado. Early stopping + L1/L2 regularizacion + Optuna evitan sobreajuste severo.
Missing values	Nativo en GBDT — aprende optimo para NaN	Puede aprender que la ausencia misma es informativa, sin necesidad de imputacion previa.
Estabilidad de datos	PSI < 0.002 (muy estable)	Baja deriva entre train y test. El modelo generaliza bien sin ajustes adicionales.

Las violaciones de supuestos del GLM son esperables en datos financieros y no invalidan su uso como **baseline interpretable y referencia regulatoria**. LightGBM elude estos problemas pero requiere monitoreo activo de estabilidad.

c. Preprocesamiento y Feature Engineering

Todas las transformaciones se encapsulan en la clase **RiskPreprocessor** con interfaz fit/transform, garantizando cero data leakage. El objeto serializado como **preprocessor.pkl** se reutiliza idénticamente en producción.

Tratamiento de missing values y outliers

Variable	Problema	Tratamiento
X1, X2, X5, X7, X11, X12	NaN aislados (786 a 16,398)	Imputación por mediana de entrenamiento + flag binario (X_sin_dato)
X3, X4	Centinelas -9999998 (15k-20k registros)	Reemplazar por NaN, luego mediana + flag binario. El centinela no es dato numérico.
X11 y X12	Siempre faltan juntos (1,720 casos)	Flag co_missing_X1_X2: ausencia conjunta es señal estructural de ausencia bancaria.
X9 (distritos)	912 vacíos + cardinalidad alta (26 valores)	Target encoding suavizado (k=10): media ponderada del TARGET por distrito.
Outliers numéricos	Valores extremos en X1, X7	Capping por percentil 99. Transformación log para comprimir la escala.

Feature engineering aplicado

Feature creada	Formula	Motivo
X1_log	$\log(X1 + 1)$	Normaliza ingreso right-skewed; mejora linealidad en GLM
X7_log	$\log(X7 + 1)$	Normaliza score buro; reduce influencia de outliers
score_x_ingreso	$X1_log \times X7$	Interacción capacidad de pago x historial. Driver 1 con 38% SHAP.
X6_x_score_ingreso_*	X6 (categorica) x score_x_ingreso	El segmento laboral modifica el efecto del ingreso sobre el riesgo.
co_missing_X1_X2	1 si X1 Y X2 son NaN	Patrón de ausencia conjunta: señal de ausencia total de historial bancario.
X9_target_enc	E[TARGET distrito] suavizado	Reemplaza 26 dummies por un único ordinal; reduce overfitting geográfico.

Pipeline produce **47 features finales** desde las 12 variables originales.




Figura c.1 — Comparacion antes/despues del preprocesamiento en features seleccionadas.




Figura c.2 — Tratamiento de outliers por capping en X1.

Figura c.3 — TARGET para registros con/sin centinela en X3.

d. Metricas de Rendimiento y Comparacion

Se calculan metricas de regresion (R2, RMSE) y metricas de discriminacion bancaria (Gini = 2xAUC-1, KS) sobre el conjunto de test (16,667 obs). Se evaluan cuatro modelos: GLM, LightGBM, XGBoost y CatBoost.

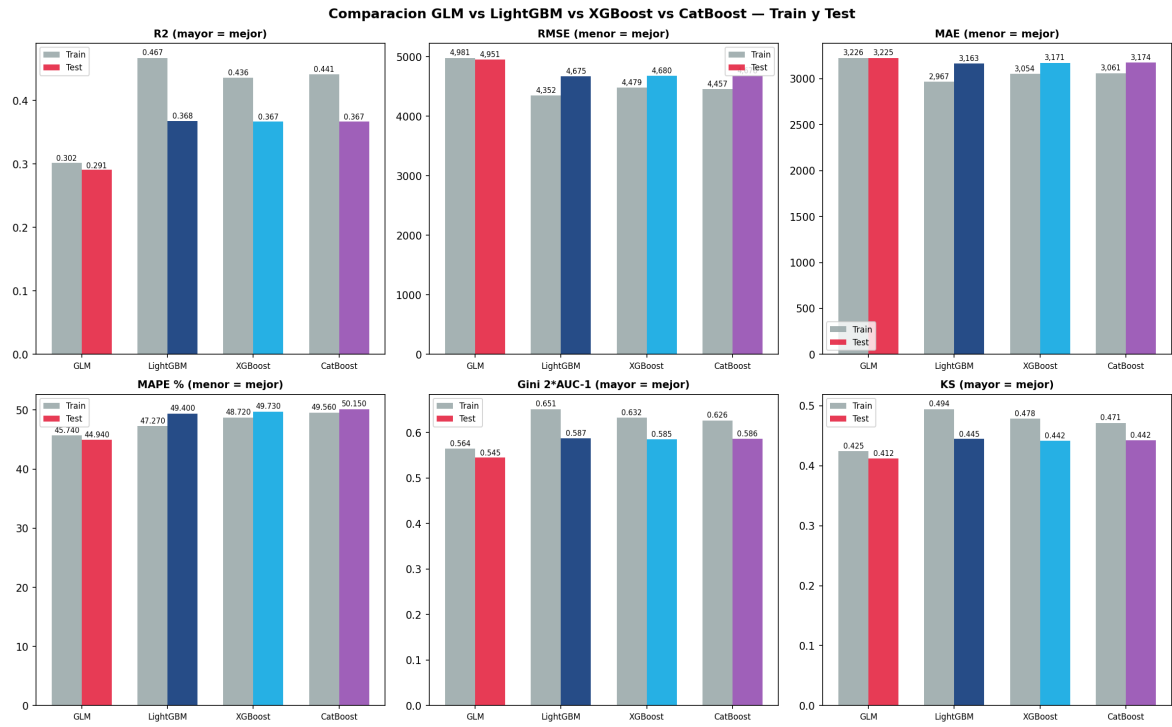


Figura d.1 — Comparacion de metricas clave. LightGBM domina en todas las dimensiones de test.

Modelo	R2 Train	R2 Test	RMSE Test (S/.)	KS Test	Gini Test
LightGBM	0.467	0.368	4,675	0.444	0.587
CatBoost	0.441	0.367	4,678	0.442	0.586
XGBoost	0.436	0.367	4,680	0.442	0.585
GLM	0.302	0.291	4,951	0.412	0.545

Gini = 2 x AUC - 1, binarizando TARGET por la mediana. Estandar de discriminacion en scoring bancario (umbral industria: Gini > 0.40 aceptable, > 0.55 bueno).

Los tres modelos GBDT convergen en R2 test aprox. 0.367, indicando que se ha alcanzado el **techo informacional** del dataset con las features disponibles. LightGBM lidera marginalmente en todas las metricas y es el que se selecciona.




Figura d.2 — Deciles LightGBM: ordena correctamente (decil 10: S/17,200 vs decil 1: S/3,820).




Figura d.3 — Distribucion de predicciones vs. reales. LightGBM captura mejor la cola alta.




Figura d.4 — Deciles GLM: ordena bien los tramos medios pero subestima la cola alta (decil 10).

e. Interpretacion de Variables

La interpretabilidad es un requisito regulatorio clave (directrices SBS, Marco de Riesgo de Modelos). LightGBM se explica mediante **SHAP values** (SHapley Additive exPlanations), que descomponen cada prediccion en contribuciones individuales por variable con garantia de consistencia matematica (axiomas de Shapley). El GLM ofrece coeficientes directos como referencia alternativa.

Importancia SHAP y coherencia con el negocio crediticio




Figura e.1 — Importancia SHAP media por variable. Figura e.2 — SHAP summary: cada punto es un cliente.
Rojo = valor alto de la feature.

Variable	Efecto	Lectura de negocio / riesgo
score_x_ingreso	Positivo dominante (38%)	Ingreso alto + buen historial juntos: predictor mas robusto del score. Coherente con toda la teoria crediticia.
X1_log (ingreso)	Positivo fuerte	Mayor capacidad de pago implica menor riesgo y mayor score. Signo esperado.
X7 (score buro)	Positivo fuerte	Historial crediticio positivo predice calidad futura. Validado por GLM (coeficiente positivo significativo).
X9_enc (distrito)	Positivo moderado	Zonas de alto ingreso medio (Miraflores, San Isidro) predicen scores mayores. Target encoding captura efecto geografico.
co_missing_X1_X2	Negativo	Ausencia simultanea de ingreso y saldo bancario: senal de ausencia total de historial. Alto riesgo.
X3_sin_dato	Negativo	Sin registro en X3: cliente sin relacion previa, mayor incertidumbre de scoring.
Interacciones X6	Moderador	El tipo de empleo modifica el efecto del ingreso: independiente con igual sueldo tiene mayor variabilidad de score.

Los signos SHAP del LightGBM son coherentes con los coeficientes del GLM, lo que da confianza en que los drivers son robustos y no artefactos del modelo de ML.

f. Seleccion del Modelo: ¿Cual implementaria?

Implementaria LightGBM. Supera al GLM en todas las metricas relevantes (R2 +26%, RMSE -5.6%, Gini +7.7%) y ofrece interpretabilidad regulatoria via SHAP por cliente. El GLM se mantiene como **modelo de referencia y respaldo regulatorio** por su transparencia directa en coeficientes.

Trade-offs: performance vs. interpretabilidad

Dimension	LightGBM (recomendado)	GLM (referencia)
R2 / Gini / KS	0.368 / 0.587 / 0.444	0.291 / 0.545 / 0.412
RMSE (S/.)	4,675 (-5.6%)	4,951
Supuestos	No parametrico — no aplica	Heterocedasticidad y no-normalidad violadas
Interpretabilidad	SHAP por cliente (mas costoso)	Coeficientes directos (inmediata)
Auditoria regulatoria	Requiere explicacion post-hoc	Directamente auditable
Latencia / tamano	< 1ms / 1.2 MB (ONNX)	< 1ms / 37 MB
Retraining	Mensual con Optuna o transfer learning	Mensual, mas rapido

Riesgos identificados y mitigaciones

Riesgo	Evidencia actual	Mitigacion
Overfitting moderado	Gap R2 train-test = 0.099	Early stopping + regularizacion L1/L2 + CV 3-fold en Optuna
Deriva de features (drift)	PSI actual < 0.002 — estable	Monitoreo mensual de PSI; retraining automatico si PSI > 0.25
Concentracion en un driver	score_x_ingreso = 38% SHAP	Alertas si la distribucion de X1 o X7 cambia > 5% mensual
Explicabilidad regulatoria	Caja gris — no transparente por defecto	SHAP por cliente disponible en API; GLM como benchmark publico de referencia
Dependencia de ONNX Runtime	Nueva dependencia de infraestructura	Fallback al.pkl de LightGBM en entornos con libgomp disponible

g. Estabilidad del Modelo y Metricas de Monitoreo

El **Population Stability Index (PSI)** es el estandar bancario para detectar si la poblacion que ingresa al modelo en produccion difiere de la de entrenamiento, lo que indica que el modelo puede estar desactualizado. Se complementa con metricas de rendimiento reales (cuando hay etiquetas disponibles) y monitoreo de la distribucion del TARGET (concept drift).

Regla de decision: $PSI < 0.10$ = sin cambio significativo | $0.10-0.25$ = cambio moderado, monitorear | > 0.25 = cambio severo, reentrenar.




Figura g.1 — PSI por feature (train vs. test). Todos < 0.002 — muy estables.

Figura g.2 — PSI del score predicho (train vs. test). Alta estabilidad poblacional.

Estrategia completa de monitoreo

Metrica / Componente	Frecuencia	Umbral de alerta	Accion
PSI del score predicho	Mensual	> 0.25	Reentrenar con datos del ultimo mes
PSI de X1, X7, X9	Mensual	> 0.10	Alertar al equipo; analizar causa raiz
Distribucion del TARGET	Mensual	Shift $> 10\%$	Analizar concept drift — cambio en el fenomeno subyacente
R2 y Gini reales	Trimestral	Degradacion $> 5\%$	Iniciar ciclo de reentrenamiento
Cambios en poblacion	Mensual	Nuevo segmento $> 5\%$	Revisar si el modelo cubre el nuevo segmento
Estado API (/health)	Continuo	model_ready = false	Alerta inmediata; rollback automatico

h. Modelo en Produccion

El flujo de produccion tiene tres fases — entrenamiento, scoring y monitoreo — que funcionan de forma modular. La API REST ya esta desplegada en Vercel con el modelo LightGBM en formato ONNX.

ENTRENAMIENTO	Carga mensual de datos crudos → validacion de schema → RiskPreprocessor.fit(X_train, y_train) → Optuna HPO (30 trials, 3-fold CV) → early stopping → exportar lgbm_model.onnx y preprocessor.pkl → correr suite de 47 tests.
SCORING	Ingesta de nuevo batch → RiskPreprocessor.transform(X) — mismo objeto fit → 47 features → ONNX Runtime inference (lgbm_model.onnx, 1.2 MB) → score en S/. por cliente. Latencia < 1ms, sin dependencia de libgomp.
MONITOREO	PSI mensual de features y score vs. ventana de referencia → R2/Gini trimestrales cuando hay etiquetas → trigger de reentrenamiento si PSI > 0.25 o degradacion > 5% → dashboard de drift + alertas al equipo de riesgo.

API REST — endpoints del servicio (ya en produccion en Vercel)

Metodo	Endpoint	Descripcion
GET	/health	Estado del servicio y disponibilidad del modelo ONNX
GET	/model/info	Metadatos: 47 features, version, tipo LightGBM ONNX
POST	/predict	Prediccion individual: recibe X1-X12, retorna score en S/. + request_id
POST	/predict/batch	Prediccion en lote: hasta 10,000 registros por llamada

```
POST /predict {"X1": 207137, "X7": 633, "X9": "SANTIAGO DE SURCO", ...} -> {"prediction": 9565.58, "request_id": "ca957d03-..."}
```

Despliegue en **Vercel** (serverless, sin dependencia libgomp, ONNX Runtime) y **Docker** (python:3.11-slim, 405 MB) para entornos on-premise. CI/CD en GitHub Actions: 47 pruebas en cada push a main.

Acceso al Proyecto

El modelo esta desplegado y operativo. Puede ser consultado de forma inmediata:

INTERFAZ WEB INTERACTIVA — Frontend del Predictor

<https://modelo-task.vercel.app>

Perfiles de cliente preconfigurados | Score en tiempo real | Badge de nivel de riesgo

API REST EN PRODUCCION — Vercel (Serverless)

<https://modelo-task.vercel.app/docs>

GET /health | GET /model/info | POST /predict | POST /predict/batch

CODIGO FUENTE — GitHub

github.com/josefrodrim/MODELO_TASK

Notebooks ejecutados | Codigo modular (src/) | 47 tests | CI/CD | Docker | Vercel

Contenido del repositorio

- **notebooks/** Analisis exploratorio, preprocesamiento, GLM, LightGBM y comparacion (con outputs)
- **src/** Codigo fuente modular — preprocessing, modelos, metricas, API REST
- **models/** lgbm_model.onnx (1.2 MB) + preprocessor.pkl — listos para produccion
- **tests/** 47 pruebas pytest — metricas, preprocesamiento y endpoints API
- **scripts/** train_all_models.py — entrena GLM + LightGBM + XGBoost + CatBoost
- **Dockerfile** Imagen python:3.11-slim con healthcheck integrado
- **vercel.json** Despliegue serverless — ONNX Runtime, sin libgomp